

RELATÓRIO DE BENCHMARKING DE MODELOS – CLÉLIO


1. Contexto

Este relatório consolida o benchmarking de modelos de linguagem em auditoria clínica (LLM-as-a-judge). Onde se realizou uma avaliação comparativa de três modelos de linguagem de grande porte (Gemini, GPT e Grok) em um conjunto de tarefas médicas estruturadas em dois formatos: 27 questões de múltipla escolha (MCQ) com gabarito objetivo e 17 questões abertas avaliadas pela métrica *must_have_score* (0–5), que pontua a presença dos elementos clinicamente obrigatórios na resposta. O objetivo é diagnosticar não apenas qual modelo acerta mais, mas onde cada um falha, quão consistentes são entre si e quais diretrizes de uso emergem para cenários de apoio à decisão clínica.


2. Painel de indicadores global

Indicador	Gemini	GPT	Grok
Acurácia MCQ	85.2%	92.6%	66.7%
Acertos MCQ (de 27)	23	25	18
Média <i>must_have_score</i> (0-5)	4.35	4.29	4.41
Score composto (0-5)	4.30	4.46	3.87

2.1 MCQ



2.2 Questoes abertas




3. Ranking de modelos

O ranking adota um score composto (0–5) que pondera igualmente a acurácia em MCQ (reescalada de 0–100% para 0–5) e a média de *must_have_score* nas abertas. Essa composição evita privilegiar modelos especialistas em apenas um dos formatos.


Modelo	Score (0-5)	Pontos fortes	Ponto fraco
GPT	4.46	Maior acurácia em MCQ; baixa variância	Levemente abaixo nas abertas
Gemini	4.30	Equilíbrio entre formatos; boa cobertura	Sem destaque absoluto em nenhum eixo
Grok	3.87	Melhor nas abertas; respostas detalhadas	Acurácia MCQ baixa (66.7%)

3.1 Ranking do score composto



4. Matriz de concordância

A matriz abaixo estima a probabilidade de dois modelos concordarem em uma mesma questão MCQ (ambos certos ou ambos errados), derivada das acurácias observadas assumindo independência. Valores altos sugerem que usar dois modelos juntos como verificação cruzada traz pouco ganho marginal; valores mais baixos indicam complementaridade.



O GPT × Gemini têm a maior concordância esperada (~80%), logo o ganho de combinar ambos é limitado. Já GPT × Grok e Gemini × Grok são mais complementares. Uma estratégia de *ensemble* com voto majoritário tende a reduzir mais erros nessas combinações

5. Conclusões

Não existe vencedor absoluto. GPT lidera em precisão objetiva, Grok lidera em completude textual, Gemini é o mais consistente entre formatos. A diferença máxima no score composto é pequena (~0.20 ponto), o que indica que a escolha ideal depende do caso de uso, não de uma superioridade global.

Há um contraste interessante: o modelo com pior desempenho no MCQ (Grok) foi o melhor em respostas dissertativas, sugerindo perfis distintos de raciocínio entre os modelos.